

KKBox Churn Prediction

KKBox Churn Prediction, o chamado "Spotify de Taiwan", é uma base riquíssima porque reflete exatamente a bagunça e a complexidade dos dados no mundo corporativo.

1. Tabela de Treino/Alvo (`amostra_train.csv`)

Esta é a tabela mais simples, mas a mais importante. Ela define quem é o cliente e se ele cancelou ou não o serviço. É a nossa "variável resposta".

- **msno**: ID único do usuário (uma hash gigante, tipo `+tJonass/q...`). É a "chave" que usaremos para fazer os JOINS com as outras tabelas.
 - **is_churn**: Nossa variável alvo. Indica se o usuário cancelou a assinatura.
 - 1 = Sim, deu churn (cancelou).
 - 0 = Não, reteve (continuou ativo).
-

2. Tabela de Perfil do Cliente (`amostra_members.csv`)

Contém os dados demográficos e de cadastro. Aqui é onde as alunas vão treinar muita limpeza de dados na Semana 3, pois tem muitos valores atípicos (outliers).

- **msno**: ID único do usuário.
 - **city**: Código numérico da cidade onde o usuário mora (ex: 1, 4, 13).
 - **bd**: Idade do usuário (*Birth Date / Age*). **Atenção aqui**: No mundo real, os usuários mentem ou preenchem errado. Vocês vão encontrar idades como -43 ou 1050 anos. Excelente para treinar tratamento de dados!
 - **gender**: Gênero do usuário (Feminino, Masculino ou Nulo/Vazio).
 - **registered_via**: Código do canal por onde o usuário se cadastrou (ex: via Facebook, Google, e-mail direto).
 - **registration_init_time**: Data em que o usuário criou a conta no aplicativo (formato YYYYMMDD).
 - **expiration_date**: Data prevista para a expiração da assinatura atual.
-

3. Tabela de Transações Financeiras (`amostra_transactions.csv`)

Traz o histórico de pagamentos. É ótima para entender se o preço ou a forma de pagamento influenciam no cancelamento.

- **msno**: ID único do usuário.
- **payment_method_id**: Código numérico do método de pagamento (ex: cartão de crédito, boleto, operadora de celular).

- **payment_plan_days**: Duração do plano contratado em dias (ex: 30 para mensal, 365 para anual).
 - **plan_list_price**: Preço de tabela do plano.
 - **actual_amount_paid**: Valor que o usuário *realmente* pagou (pode ser menor que o preço de tabela se ele usou cupom de desconto).
 - **is_auto_renew**: Flag que indica se a renovação automática está ativada (1 = Sim, 0 = Não).
 - **transaction_date**: Data em que a transação de pagamento ocorreu (YYYYMMDD).
 - **membership_expire_date**: Nova data de expiração da assinatura após esse pagamento.
 - **is_cancel**: Flag que indica se a transação é, na verdade, um pedido de cancelamento ativo (1 = Cancelou, 0 = Não).
-

4. Tabela de Comportamento/Logs (amostra_user_logs.csv)

É a tabela mais pesada e granular. Ela registra o que o usuário fez no aplicativo dia após dia. É daqui que tiramos os insights de "engajamento" (quantas músicas ouviu, quanto tempo ficou).

- **msno**: ID único do usuário.
- **date**: Data específica do log/acesso (YYYYMMDD).
- **num_25**: Quantidade de músicas que o usuário ouviu até 25% (pulou rápido, não gostou).
- **num_50**: Quantidade de músicas ouvidas entre 25% e 50%.
- **num_75**: Quantidade de músicas ouvidas entre 50% e 75%.
- **num_985**: Quantidade de músicas ouvidas quase até o fim (entre 75% e 98.5%).
- **num_100**: Quantidade de músicas ouvidas inteiras (mais de 98.5%). **Forte indicador de engajamento.**
- **num_unq**: Número de músicas *únicas* que ele ouviu no dia (descobrimos novos sons vs. repetindo as mesmas).
- **total_secs**: Total de segundos que o usuário passou ouvindo música naquele dia.

Brazilian E-Commerce Public Dataset by Olist

A base da Olist simula um banco de dados relacional clássico de e-commerce com várias tabelas conectadas.

1. Tabela de Clientes (olist_customers_dataset)

Aqui estão os dados de quem comprou.

- **customer_id:** Chave do cliente atrelada ao pedido. **A Pegadinha:** A cada nova compra, o sistema gera um novo customer_id. Ele serve para cruzar com a tabela de Pedidos.
- **customer_unique_id:** O "CPF" real do cliente. É essa coluna que usamos para saber se o cliente fez mais de uma compra na loja (recompra).
- **customer_zip_code_prefix:** Os 5 primeiros dígitos do CEP.
- **customer_city:** Cidade do cliente.
- **customer_state:** Estado do cliente. Ótimo para mapas no dashboard (Semana 4).

2. Tabela de Pedidos (olist_orders_dataset)

A "espinha dorsal" da base. É ela que conecta o cliente, o pagamento e os produtos. Ideal para análises de logística e tempo de entrega.

- **order_id:** Chave única do pedido.
- **customer_id:** Chave para cruzar com a tabela de clientes (para saber de onde é a pessoa que fez o pedido).
- **order_status:** Status do pedido (ex: delivered, shipped, canceled).
- **order_purchase_timestamp:** Data e hora exata da compra.
- **order_approved_at:** Data e hora que o pagamento foi aprovado.
- **order_delivered_carrier_date:** Quando o pedido foi entregue à transportadora.
- **order_delivered_customer_date:** Data real em que chegou na casa do cliente. *(Subtrair essa data da data de compra dá o tempo de entrega!)*
- **order_estimated_delivery_date:** Data prometida para entrega. *(Cruzar com a data real mostra se houve atraso).*

3. Tabela de Itens do Pedido (olist_order_items_dataset)

Mostra "o que" tem dentro de cada caixinha de pedido. Se a pessoa comprou 3 cadeiras e 1 mesa no mesmo pedido, haverá 4 linhas aqui.

- **order_id:** Chave para cruzar com a tabela de Pedidos.
- **order_item_id:** Número sequencial do item dentro daquele pedido (ex: item 1, item 2).
- **product_id:** Chave única do produto (cruza com a tabela de Produtos).
- **seller_id:** Chave do lojista parceiro que vendeu aquele item.
- **price:** Preço do produto.
- **freight_value:** Valor do frete cobrado por aquele item específico.

4. Tabela de Pagamentos (olist_order_payments_dataset)

Como o dinheiro entrou.

- **order_id**: Chave para cruzar com a tabela de Pedidos.
- **payment_sequential**: Se o cliente pagou com 2 cartões diferentes, aqui marca 1 e 2.
- **payment_type**: Método de pagamento (ex: credit_card, boleto, voucher).
- **payment_installments**: Quantidade de parcelas.
- **payment_value**: Valor total daquela transação.

5. Tabela de Avaliações (olist_order_reviews_dataset)

A voz do cliente. Excelente para a análise exploratória (Semana 4 e 5), pois permite cruzar a "nota" com "atraso na entrega" ou "preço do frete".

- **review_id**: Chave única da avaliação.
- **order_id**: Chave do pedido avaliado.
- **review_score**: A nota que o cliente deu, de 1 a 5 estrelas. **(KPI principal de satisfação)**.
- **review_comment_title**: Título do comentário.
- **review_comment_message**: O texto do comentário. *(Muitos estarão vazios, bom para ensinar tratamento de nulos)*.
- **review_creation_date**: Quando o questionário de satisfação foi enviado.
- **review_answer_timestamp**: Quando o cliente respondeu.

6. Tabela de Produtos (olist_products_dataset)

Características físicas do que foi vendido.

- **product_id**: Chave única do produto.
- **product_category_name**: Nome da categoria (ex: beleza_saude, cama_mesa_banho).
- **product_weight_g**: Peso em gramas.
- **product_length_cm / height_cm / width_cm**: Dimensões do pacote (Comprimento, altura, largura).

Tabelas de Suporte (Menos prioritárias para o início)

- **olist_sellers_dataset**: Dados dos lojistas (cidade, estado). Igual à de clientes, mas para o vendedor.
- **olist_geolocation_dataset**: Uma base de dados gigante relacionando CEPs a latitudes e longitudes. *(Recomendo pular essa, pois pode travar os compiladores online por ser muito pesada)*.
- **product_category_name_translation**: Apenas uma tabelinha de "De/Para" traduzindo as categorias do Português para o Inglês.